

Génération, Structure & Exploitation du Dataset

Guide complet pour comprendre la mécanique interne du script synthétique et réussir sa modélisation prédictive (filiere_recommandee)

3 000

LIGNES GÉNÉRÉES

12

MATIÈRES (FEATURES)

10

FILIÈRES (CLASSES)

4

PROFILS D'ÉTUDIANTS

1. Analyse Détaillée du Script Pas à Pas

Étape 1 : Initialisation & Constantes Globale

Le script définit une graine de fixité (`RNG_SEED = 42`) pour garantir la reproductibilité exacte. `N_PER_CLASS = 300` assure une répartition rigoureusement équilibrée de 300 étudiants par filière. Le bruit aléatoire gaussien est contrôlé par `NOISE_STD = 1.6`.

Étape 2 : Modélisation Métier des Filières

Un dictionnaire structuré associe à chaque filière ses contraintes :

- **required** : Matières fondamentales à fort coefficient.
- **flavor** : Matières secondaires susceptibles de recevoir un bonus.
- **single_rule** : Règles de dominance d'une seule matière forte.

Étape 3 : Logique de Génération des Notes (`make_row`)

Chaque ligne est construite dynamiquement :

- Toutes les 12 matières reçoivent une note de base tirée selon $\mathcal{N}(9.5, 1.6^2)$.
- Application d'un des 4 profils d'étudiant :
 - **Extreme** : Notes entre 15.0 et 20.0 dans toutes les matières requises.
 - **Moderate** : Notes entre 12.0 et 16.5 dans les matières requises.
 - **Single** : Excellence (15.0-20.0) sur une seule matière clé.
 - **Borderline** : Moyenne autour de 10.0 avec léger sursaut (+0.5 à +2.0).
- Ajout conditionnel d'un bonus "flavor" (40% de chances, +1.0 à +3.0 points).
- Troncature et arrondi strict dans $[0.00, 20.00]$ via `clip_round()`.

Étape 4 : Mélange et Formatage d'Export

Les données sont réorganisées, mélangées de manière aléatoire (`sample(frac=1.0)`) pour briser l'ordre des classes, puis exportées dans `data/raw/dataset_note_etudiant_bac.csv` au format européen (séparateur ; et décimale ,).

2. Cartographie des 10 Filières et Matières Exigées

Filière Recommandée	Matières Requises ('required')	Règle Particulière
Cybersécurité et Réseaux	Mathématiques, Test Psychotechnique	Standard
Science des Données & IA	Maths, Stats/Probas, Test Psychotechnique	Standard

Filière Recommandée	Matières Requises ('required')	Règle Particulière
Médecine et Pharmacie	Biologie Appliquée, Chimie	Flavor: SVT Single Rule
Tourisme et Hôtellerie	Histoire-Géo, Français, Anglais	Single Rule: Histoire-Géo
Langues et Communication	Français, Anglais	Single Rule
Sociologie	Philosophie, Anglais, Français	Single Rule: Philosophie
Science Actuarielle	Maths, Stats/Probas, Français, Anglais	Standard
Ingénierie et Science	Maths, Physique, Chimie, Dessin Tech, Test Psych.	Single Rule (Maths/Phys/Dessin)
Droit & Sciences Politiques	Histoire-Géo, Français, Anglais, Test Psych.	Standard
Psychologie	Philosophie, Test Psychotechnique	Single Rule: Test Psych.

3. Stratégie d'Exploitation Maximale (Machine Learning)

Chargement Correct du Fichier CSV

En raison du formatage spécifique du script (décimale , et séparateur ;), chargez toujours le dataset comme suit :

```
import pandas as pd

df = pd.read_csv('data/raw/dataset_note_etudiant_bac.csv', sep=';', decimal=',')
```

A. Feature Engineering Avancé

Pour dépasser les performances de base et capturer la structure complexe des notes :

- **Aggrégations par Domaine** : Créez des moyennes sectorielles (ex. Moyenne_Scientifique, Moyenne_Littéraire, Moyenne_Technique).
- **Indices de Spécialisation** : Calculez l'écart-type inter-matières par étudiant pour mesurer s'il s'agit d'un profil polyvalent ou fortement spécialisé.
- **Écarts à la Moyenne Individuelle** : Soustrayez la moyenne générale de l'étudiant à chacune de ses notes pour identifier ses points forts relatifs indépendamment de son niveau global.

B. Pipeline d'Entraînement et Benchmarking

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, confusion_matrix

# Isolation des features et de la cible
X = df.drop(columns=['filiere_recommandee'])
y = LabelEncoder().fit_transform(df['filiere_recommandee'])

# Découpage stratifié
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)
```

```
# Modélisation
model = RandomForestClassifier(n_estimators=200, max_depth=12, random_state=42)
model.fit(X_train, y_train)

# Évaluation
y_pred = model.predict(X_test)
print(classification_report(y_test, y_pred))
```

C. Diagnostic & Interprétabilité

- **Matrice de Confusion** : Analysez où se produisent les chevauchements (ex. confusion entre *Data Science* et *Cybersécurité* en raison du socle commun en Mathématiques et Tests Psychotechniques).
- **Analyse SHAP / Importance des Caractéristiques** : Vérifiez si le modèle réapprend fidèlement les règles métier configurées dans le script original.